

UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas – ICEx

Departamento de Ciência da Computação

Bancos de Dados Geográficos e Ciência de Dados Geoespaciais (2026/2)

Professor: Clodoveu Davis

Trabalho Prático – Parte 1: Engenharia de Dados e Análise Exploratória

Análise Espacial Integrada de Segurança Pública (IPS Brasil) e
Desempenho Educacional (IDEB/INEP) nos Municípios Brasileiros

Integrantes do Grupo:

Integrantes do Grupo:

Nome: Bruno Soares e Silva

Nome: Bernardo Alves Miranda

Nome: Camila Nicola Dias Santana

Nome: Igor Novais Barroso

Nome: Lucas Albuquerque Santos Costa

Nome: Thaylor Weslei Dias Godinho Verteiro

Repositório do GitHub:

https://github.com/Thaylor2008/TP_BDG_Elei-oes2026.git

Belo Horizonte – MG
25 de setembro de 2026

Sumário

1	Introdução	3
2	Tema Complementar Municipal: Segurança Pública x Educação	3
2.1	Justificativa e Critérios de Escolha	3
2.2	Fonte e Aquisição dos Dados	3
2.3	Processo de Engenharia de Dados (ETL) e Pareamento de Chaves	4
2.4	Processo de Carga no PostgreSQL/PostGIS	5
3	Dados de Referência e Censitários (IBGE 2022)	6
3.1	Estruturação da Malha Territorial	6
3.2	Seleção de Atributos Socioeconômicos e Demográficos	6
3.3	Procedimentos de Agregação e Integração Espacial	6
4	Análise Exploratória de Dados (EDA)	7
4.1	Qualidade da Base de Dados e Limpeza	7
4.2	Estatísticas Descritivas Básicas	7
4.3	Distribuição Espacial e Variabilidade	7
5	Análise Crítica e Limitações da Base Preparada	9
5.1	Potencial Analítico da Base	9
5.2	Limitações Identificadas	9
6	Conclusão e Próximos Passos	10

1 Introdução

O estudo espacial de fenômenos políticos e sociais exige a construção de bases de dados geospaciais (BDG) robustas, integradas e padronizadas. No contexto das Eleições de 2026, compreender o comportamento do eleitorado brasileiro requer transcender a mera contagem de votos e analisar as condicionantes socioeconômicas, estruturais e de qualidade de vida que influenciam as dinâmicas locais em nível municipal.

Este relatório apresenta os resultados da **Parte 1 do Trabalho Prático da disciplina de Bancos de Dados Geográficos e Ciência de Dados Geospaciais (DCC/UFGM)**. O objetivo principal desta primeira etapa consiste no desenvolvimento de um pipeline completo de Engenharia de Dados e Análise Exploratória de Dados (EDA). A rotina engloba a aquisição, filtragem, limpeza, normalização textual, pareamento de chaves espaciais heterogêneas, carga estruturada no servidor PostgreSQL 17.5 / PostGIS 3.5.2 e caracterização estatística e geográfica dos indicadores integrados.

O tema complementar selecionado pelo grupo une dois pilares fundamentais do debate político nacional: **Segurança Pública** (mensurada via Índice de Progresso Social – IPS Brasil 2026) e **Desempenho Educacional** (mensurado via Índice de Desenvolvimento da Educação Básica – IDEB/INEP e dados do ENEM). A base unificada abrange os 5.570 municípios do território brasileiro, servindo de alicerce para as análises de autocorrelação espacial (I de Moran) e correlação eleitoral que serão executadas na Parte 2 do projeto após o término da apuração do primeiro turno das Eleições de 2026.

2 Tema Complementar Municipal: Segurança Pública x Educação

2.1 Justificativa e Critérios de Escolha

A escolha integrada dos temas de **Segurança Pública** e **Educação** fundamenta-se na hipótese de que a vulnerabilidade social e a violência urbana exercem impacto direto sobre o ambiente escolar e a fixação de capital humano, constituindo eixos centrais nas plataformas de campanha eleitoral. Municípios com elevadas taxas de homicídios e violência comunitária frequentemente enfrentam maiores taxas de evasão escolar e pior desempenho em exames nacionais. Por outro lado, a oferta de educação pública de qualidade atua como fator estrutural de prevenção à criminalidade.

Ao integrar os dados do **IPS Brasil 2026** (que detalha homicídios, assassinatos de jovens e mulheres, mortes no trânsito e violência doméstica) com os indicadores do **IDEB** (Anos Iniciais, Anos Finais e Ensino Médio da rede pública) e a Nota Mediana do ENEM, o grupo estruturou uma base com alto valor analítico para avaliar a efetividade de políticas públicas e suas intersecções com a preferência do eleitorado nas urnas.

2.2 Fonte e Aquisição dos Dados

Os dados temáticos foram coletados de fontes oficiais e institucionais abertas de alta credibilidade:

1. **IPS Brasil 2026 (IPS Brasil 2026 - Tabela de Dados_Brasil.csv):** Mantido pelo Instituto Homem e Meio Ambiente da Amazônia (Imazon) e parceiros. Fornece o Índice de Progresso Social geral e subíndices de Segurança Pessoal, Violência contra Mulheres, Jovens, Negros e Indígenas, bem como a Nota Mediana do ENEM por município.
2. **IDEB / INEP (divulgacao_anos_iniciais_...xlsx, ...anos_finais..., ...ensino_medio...):** Microdados oficiais do Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira referente às avaliações do SAEB e fluxo escolar para as redes públicas (estadual e municipal), utilizando dados de 2023/2025.

2.3 Processo de Engenharia de Dados (ETL) e Pareamento de Chaves

Um dos maiores desafios de Engenharia de Dados nesta etapa decorreu do fato de a tabela do IPS Brasil não disponibilizar o código IBGE oficial do município (`cd_mun`), identificando as localidades apenas pelas colunas `Município` e `UF`. Para solucionar essa divergência e integrar a base ao IDEB (que já utiliza o `CO_MUNICIPIO` do IBGE), desenvolveu-se um algoritmo de pareamento em Python em três passadas sucessivas:

- **Passada 1 (Normalização Estrita):** Aplicação de limpeza de caracteres via codificação ASCII (NFKD), remoção de acentos, pontuações e conversão para caixa alta. Criação da chave `NOME_NORMALIZADO/UF` para pareamento com a tabela de referência oficial `geodata.munic`.
- **Passada 2 (Normalização Semântica / *Loose Match*):** Remoção de preposições e artigos genéricos (DE, DO, DA, DOS, DAS, D'). Essa etapa corrigiu nomes com variações ortográficas de conectivos.
- **Passada 3 (Dicionário de Exceções Manuais):** Mapeamento direto de divergências históricas ou grafias arcaicas em municípios específicos, tais como: `GRACHO CARDOSO/SE` → `2802601` (oficial: `*Graccho Cardoso*`); `ARES/RN` → `2401206` (oficial: `*Arez*`); `ACU/RN` → `2400208` (oficial: `*Assu*`); `SAO LUIZ/RR` → `1400605` (oficial: `*São Luiz do Anauá*`).

O Listing 1 apresenta o trecho do código Python desenvolvido para a execução dessa rotina de tratamento e consolidação.

```

1 import re, unicodedata, pandas as pd
2
3 def normaliza(txt: str) -> str:
4     if pd.isna(txt): return ""
5     txt = str(txt).strip().upper()
6     txt = unicodedata.normalize("NFKD", txt).encode("ascii", "ignore").
       decode("ascii")
7     txt = re.sub(r"[^A-Z0-9 ]", " ", txt)
8     return re.sub(r"\s+", " ", txt).strip()
9
10 # Pareamento em 3 passadas: estrita, loose (sem preposicoes) e correcoes
    manuais

```

```

11 ref = pd.read_csv("Dados brutos/ref/munic_ref.csv", dtype={"cd_mun": str
    })
12 ref = ref[~ref["cd_mun"].isin(["4300001", "4300002"])].copy() # Exclui
    lagoas RS
13 ref["chave"] = ref["nm_mun"].map(normaliza) + "/" + ref["sigla_uf"].str.
    upper()
14 ref_map = ref.set_index("chave")["cd_mun"].to_dict()
15
16 ips = pd.read_csv("Dados brutos/IPS Brasil 2026 - Tabela de Dados_Brasil
    .csv", encoding="utf-8-sig")
17 ips["chave"] = ips["Munic pio"].map(normaliza) + "/" + ips["UF"].str.
    upper()
18 ips["cd_mun"] = ips["chave"].map(ref_map)

```

Listing 1: Código Python para limpeza, normalização e pareamento do IPS Brasil com o IDEB.

2.4 Processo de Carga no PostgreSQL/PostGIS

A tabela consolidada final (`grupo_seguranca_educacao.csv`), contendo 5.570 municípios e 34 atributos, foi importada para o servidor PostGIS da disciplina (150.164.2.42:5432, banco `bdg2026`, schema `geodata`) sob a tabela `geodata.thaylor_verteiro_seguranca_educacao`.

Para evitar erros de inserção por tipos de dados (como estouro de limite de inteiros devido a valores ausentes convertidos para `*float*` pelo `*pandas*`), o script de carga tratou explicitamente cada valor para tipos nativos do Python antes da execução do `psycopg2.extras.execute_values`. O Listing 2 exemplifica a estrutura DDL e o procedimento de inserção.

```

1 import psycopg2, pandas as pd
2 from psycopg2.extras import execute_values
3
4 CONN = dict(host="150.164.2.42", port=5432, dbname="bdg2026", user="
    turma2026", password="turma")
5 TABELA = "thaylor_verteiro_seguranca_educacao"
6
7 ddl = f"""
8 DROP TABLE IF EXISTS geodata.{TABELA};
9 CREATE TABLE geodata.{TABELA} (
10     cd_mun varchar(7) PRIMARY KEY,
11     nm_mun varchar(120), sigla_uf varchar(2), cd_rgi varchar(10),
12     cd_rgint varchar(10),
13     area_km2 double precision, cd_tse integer, populacao_2025 double
14     precision,
15     pib_per_capita double precision, ips_geral double precision,
16     ips_seguranca_pessoal double precision, ips_homicidios double
17     precision,
18     ips_violencia_mulheres double precision, ips_nota_mediana_enem
19     double precision,
20     ideb_anos_iniciais double precision, ideb_anos_finais double
21     precision, ideb_ensino_medio double precision
22 );
23 """

```

Listing 2: Script de criação da DDL e carga no servidor PostgreSQL/PostGIS.

3 Dados de Referência e Censitários (IBGE 2022)

3.1 Estruturação da Malha Territorial

A malha espacial de referência é mantida na tabela `geodata.munic` do banco da disciplina. Para garantir a integridade das análises espaciais, foram aplicados os filtros de tratamento previstos na especificação do projeto:

1. **Exclusão de Polígonos Hidrográficos:** Remoção dos códigos 4300001 (Lagoa Mirim) e 4300002 (Lagoa dos Patos), localizados no Rio Grande do Sul. Embora façam parte da malha digital do IBGE, representam corpos d'água sem população ou administração municipal.
2. **Tratamento de Novos Municípios:** Observação referente ao município de **Boa Esperança do Norte (MT)** (código 5101837), instalado em 01/01/2025 após decisão do STF. Por não possuir dados censitários no Censo 2022, foi mantido isolado para evitar distorções de agregação.

3.2 Seleção de Atributos Socioeconômicos e Demográficos

A base de dados de referência foi enriquecida com atributos estruturais do Censo Demográfico 2022 do IBGE:

- **Demografia e População:** População projetada (`populacao_2025`), área territorial (`area_km2`) e densidade demográfica.
- **Economia:** PIB *per capita* (`pib_per_capita`), essencial para controlar o efeito da riqueza municipal sobre os indicadores de saúde, educação e criminalidade.
- **Níveis Geográficos de Agregação:** Chaves de ligação para Regiões Geográficas Imediatas (`cd_rgi`), Regiões Geográficas Intermediárias (`cd_rgint`) e Unidades da Federação (`sigla_uf`), permitindo re-agregações na Parte 2.

3.3 Procedimentos de Agregação e Integração Espacial

A tabela temática complementar `geodata.thaylor_verteiro_seguranca_educacao` relaciona-se de forma 1 : 1 com a tabela espacial `geodata.munic` através da chave primária `cd_mun` (Código IBGE de 7 dígitos). A consulta SQL abaixo ilustra como é realizada a junção geográfica para visualização e análise no QGIS:

```
1 SELECT
2     m.cd_mun, m.nm_mun, m.sigla_uf,
3     t.ips_homicidios, t.ips_nota_mediana_enem, t.ideb_ensino_medio,
4     m.geom
5 FROM geodata.munic m
6 JOIN geodata.thaylor_verteiro_seguranca_educacao t ON m.cd_mun = t.
    cd_mun;
```

Listing 3: Consulta SQL de junção entre a tabela temática e a malha espacial no PostGIS.

4 Análise Exploratória de Dados (EDA)

4.1 Qualidade da Base de Dados e Limpeza

A rotina de ETL obteve uma taxa de sucesso de **100% de pareamento para a base do IPS Brasil** (todos os 5.570 municípios pareados). Quanto ao IDEB/INEP, a cobertura é superior a 99%, registrando-se 53 valores nulos nos Anos Iniciais (0,95%), 27 nos Anos Finais (0,48%) e 52 no Ensino Médio (0,93%). Tais ausências são justificadas por municípios de pequeno porte sem rede municipal/estadual ofertante própria ou que não atingiram a taxa mínima de participação na prova do SAEB.

4.2 Estatísticas Descritivas Básicas

A Tabela 1 apresenta o resumo das estatísticas descritivas calculadas para as principais variáveis socioeconômicas, educacionais e de segurança pública do banco unificado.

Tabela 1: Estatísticas descritivas das variáveis do banco de dados unificado ($N = 5.570$ municípios).

Variável	Válidos	Faltantes (%)	Média	Desv. Padrão	Mínimo	Mediana	Máximo
População (2025)	5.570	0,00%	38.315,11	217.438,60	856,00	11.358,50	11.904.961,00
PIB per capita (R\$)	5.570	0,00%	39.026,01	38.854,28	6.771,94	29.107,21	678.813,83
IPS Geral	5.570	0,00%	60,44	4,38	42,44	60,53	73,10
IPS Segurança Pessoal	5.570	0,00%	63,77	14,95	10,65	66,99	85,22
Taxa de Homicídios	5.570	0,00%	17,50	16,03	0,00	13,14	220,27
Assassinatos de Jovens	5.570	0,00%	32,70	38,70	0,00	20,96	552,98
Violência c/ Mulheres	5.570	0,00%	200,16	230,89	0,00	127,28	2.525,71
Evasão Ensino Médio (%)	5.570	0,00%	8,72	3,23	1,27	8,30	24,46
Nota Mediana ENEM	5.570	0,00%	511,41	34,25	405,95	508,93	652,96
IDEB Anos Iniciais	5.517	0,95%	6,22	0,87	3,30	6,20	10,00
IDEB Anos Finais	5.543	0,48%	5,11	0,74	2,80	5,10	9,30
IDEB Ensino Médio	5.518	0,93%	4,47	0,58	2,40	4,50	7,20

4.3 Distribuição Espacial e Variabilidade

A análise espacial dos indicadores revela forte heterogeneidade territorial no Brasil:

- Segurança Pública e Homicídios:** A taxa média de homicídios é de 17,50 por 100 mil habitantes, apresentando extrema assimetria à direita. Vários municípios de pequeno porte registram taxa zero (0,00), enquanto polos regionais e certas faixas litorâneas do Norte e Nordeste atingem picos superiores a 100 homicídios por 100 mil hab. (máximo de 220,27). A Figura 1 ilustra a distribuição cartográfica das taxas de homicídios.
- Desempenho no ENEM e IDEB:** A Nota Mediana do ENEM apresenta média de 511,41 pontos, com distribuição concentrada nas regiões Sul e Sudeste (picos de 652,96 pontos), enquanto regiões do interior do Norte/Nordeste registram médias inferiores a 450 pontos. A Figura 2 evidencia a distribuição espacial da nota do ENEM no território nacional.

3. **Gargalo do Ensino Médio:** Observa-se uma redução progressiva nas notas médias do IDEB à medida que se avança no ciclo escolar: Anos Iniciais (6, 22), Anos Finais (5, 11) e Ensino Médio (4, 47). A taxa de evasão no Ensino Médio possui média de 8, 72%, chegando a 24, 46% em municípios em situação de alta vulnerabilidade.

Taxa de Homicídios por 100 mil habitantes em Municípios Brasileiros




Figura 1: Distribuição espacial da Taxa de Homicídios por 100 mil habitantes nos municípios brasileiros (Fonte: IPS Brasil 2026 / Elaboração do Grupo).

Nota Mediana no ENEM dos Municípios Brasileiros




Figura 2: Distribuição espacial da Nota Mediana do ENEM nos municípios brasileiros (Fonte: IPS Brasil 2026 / Elaboração do Grupo).

5 Análise Crítica e Limitações da Base Preparada

5.1 Potencial Analítico da Base

A base construída integra indicadores de vulnerabilidade social, desempenho educacional, economia e estrutura demográfica. Esse arranjo proporcionará na Parte 2 do trabalho um alto poder de explicação para:

- Avaliar se a preferência por determinados candidatos/partidos nas Eleições de 2026 possui autocorrelação espacial com áreas de alta criminalidade ou baixo desempenho educacional.
- Executar análises de **I de Moran Bivariado** cruzando votação eleitoral com a taxa de homicídios e o IDEB.
- Identificar *clusters* espaciais de alto-alto e baixo-baixo (mapas LISA) para orientação de políticas públicas regionais.

5.2 Limitações Identificadas

As principais limitações metodológicas identificadas no processo incluem:

1. **Janelas Temporais Distintas:** Os dados do Censo referem-se a 2022, os dados do IPS a 2026 e os microdados do IDEB a 2023/2025. Embora representem a

melhor informação disponível em nível municipal, pequenas defasagens devem ser ponderadas.

2. **Ausência de Dados em Exceções Espaciais:** Conforme pontuado nas especificações da disciplina, o município de Boa Esperança do Norte (MT) não possui dados censitários de 2022.
3. **Agregação Municipal:** Dados agregados por município podem ocultar disparidades intraurbanas acentuadas que ocorrem em grandes metrópoles (como São Paulo e Rio de Janeiro).

6 Conclusão e Próximos Passos

A Parte 1 do trabalho cumpriu com êxito todas as etapas de Engenharia de Dados e Análise Exploratória. O pipeline em Python garantiu 100% de pareamento dos municípios, a tabela foi adequadamente estruturada e disponibilizada no servidor PostgreSQL/PostGIS da UFMG e o relatório em LaTeX sintetiza as propriedades estatísticas e territoriais da base.

Para a **Parte 2**, o grupo aguardará a publicação oficial dos dados eleitorais pelo TSE após o primeiro turno das Eleições de 2026 para executar as rotinas de agregação espacial nos níveis de Região Imediata, Intermediária e Estado, bem como os testes formais de autocorrelação e correlação espacial.